

Bachelorarbeit

**Bootstrapping Ansätze zur Bestimmung von
Konfidenzbändern für Verteilungsfunktionen**

Dennis Richter
Monat der Abgabe

Gutachter:

Prof. Dr. Peter Buchholz

Name des Zweitgutachters

Technische Universität Dortmund

Fakultät für Informatik

Lehrstuhl für praktische Informatik (LS 4)

<https://ls4-www.cs.tu-dortmund.de>

Inhaltsverzeichnis

1	Einleitung	1
1.1	Motivation	1
1.2	Zielsetzung	2
1.3	Aufbau der Arbeit	3
2	Grundlagen	5
2.1	Simulationsstudien	5
2.1.1	M/M/1-Modell	5
2.2	Parameter-Schätzer	6
2.2.1	Maximum-Likelihood-Schätzer	6
2.3	GoF-Tests	7
2.3.1	Kolmogorov-Smirnov Test	7
2.3.2	Anderson-Darling Test	7
2.3.3	Chi-Quadrat Test	7
2.4	Konfidenzintervalle	7
2.5	Konfidenzbänder	7
2.6	Coverage Error	7
2.7	Resampling Verfahren	7
2.7.1	Bootstrap	7
3	Vorstellung der Algorithmen	9
3.1	Standard Bootstrap	9
3.2	Bootstrapping der Residuen	9
3.3	Parametrisches Bootstrap	9
3.4	Wild Bootstrap	9
3.5	Bayes'sches Bootstrap	9
3.6	Resampling von $\partial R(\alpha)$	9
4	Implementierung	11
4.1	OMNeT++	11
4.1.1	Überblick	11

4.1.2	Simulationen	11
4.2	Parameterstudien in OMNeT++	11
4.2.1	Datenerfassung	11
4.2.2	Auswertung	11
4.2.3	Darstellung	11
4.3	11
5	Auswertung	13
5.1	Analytisches Verfahren	13
5.2	parametrisches Bootstrapping	13
5.3	nicht-parametrisches Bootstrapping	13
5.4	Vergleich	13
6	Schlussteil	15
6.1	Fazit	15
6.2	Ausblick	15
A	Weitere Informationen	17
	Abbildungsverzeichnis	19
	Algorithmenverzeichnis	21
	Literaturverzeichnis	23
	Erklärung	23

Kapitel 1

Einleitung

1.1 Motivation

Bei der statistischen Analyse von Daten ist es oft üblich aufwendige theoretische Modelle vorauszusetzen zu müssen, um aussagekräftige Ergebnisse über eine Stichprobe zu erhalten.

Die Auswahl eines statistischen Modells welches das wahre Modell so gut wie möglich repräsentiert, ist oft eine Herausforderung aber gleichzeitig ausschlaggebend für den Erfolg der Analyse.

Nur bedingt erfüllte Annahmen führen zu falschen Aussagen, zu spezifische Modelle hingegen lassen sich nicht Computer gestützt umsetzen und müssen per Hand analysiert werden.

Die Simulation der wahren Population durch die gegeben Stichprobe liefern hier einen Weg, diese Schwierigkeit zu umgehen.

Die Idee solcher sogenannten Resampling-Verfahren ist aus einer kleinen Anzahl von Stichproben beliebig viele Stichproben zu generieren, indem die ursprünglichen Daten als Schätzer für die Grundgesamtheit dienen, von der nun beliebig oft gesampelt werden kann.

Anstelle eine Verteilung vorauszusetzen, kann diese so mittels Monte-Carlo-Schätzung unter sehr allgemeinen Voraussetzungen angenähert werden.

Efron ... zeigt das sogenannte Bootstrap Verfahren statistisch exakt ist und neben den zahlreichen Anwendungsgebieten überraschend gute Eigenschaften haben kann.

Einziger Nachteil ist der zu leistende Rechenaufwand, allerdings wird die Rechenleistung von Computern immer besser und günstiger.

Bootstrap Verfahren sind sehr Einfach zu implementieren und liefern somit eine wunderbare Alternative gegenüber analytischen Verfahren, um die Verteilung einer Stichprobe zu bestimmen

beliebtes anwendungsgebiet sind konfidenz intervalle für den schätzer einer zufallsvariable...

Kapitel 2

Grundlagen

2.1 Simulationsstudien

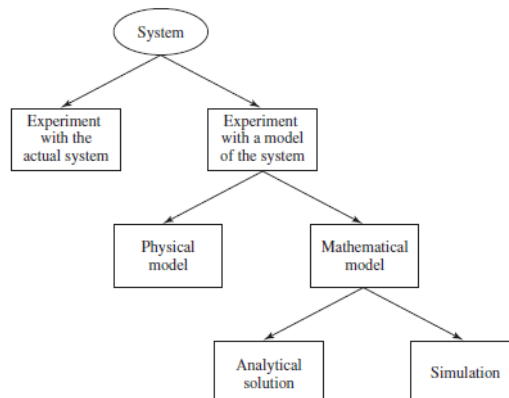


FIGURE 1.1
Ways to study a system.

Abbildung 2.1: Arten von Systemstudien

2.1.1 M/M/1-Modell



Abbildung 2.2: M/M/1 Warteschlangenmodell

$$f_T(x) = \lambda e^{-\lambda t}, \quad t \geq 0 \quad (2.1)$$

$$f_S(x) = \mu e^{-\mu t}, \quad t \geq 0 \quad (2.2)$$



Abbildung 2.3: M/M/1 Zustandsübergangsdiagramm

$$P_n = (1 - \rho)\rho^n \quad (2.3)$$

$$L = \frac{\rho}{1 - \rho} = \frac{\lambda}{\mu - \lambda} \quad (2.4)$$

$$W_q = \frac{\rho}{\mu - \lambda} = \frac{\lambda}{\mu(\mu - \lambda)} \quad (2.5)$$

2.2 Parameter-Schätzer

$$y_i = \eta(x_i, \theta) + \epsilon_i, \quad i = 1, 2, \dots, n \quad (2.6)$$

$$\epsilon \sim N(0, \sigma^2) \quad (2.7)$$

$$E(y|x) = \eta(x, \theta) \quad (2.8)$$

$$\hat{y} = \eta(x, \hat{\theta}) \quad (2.9)$$

$$\arg \min_{\theta \in \mathcal{R}} \sum_{i=1}^n [\eta(x_i, \theta) - y_i]^2 \quad (2.10)$$

$$\sum_{i=1}^n \psi(y_i, \theta) = 0 \quad (2.11)$$

2.2.1 Maximum-Likelihood-Schätzer

$$Lik(\theta, y) = \prod_{i=1}^n f(y_i, \theta) \quad (2.12)$$

$$L(\theta, y) = \log \prod_{i=1}^n f(y_i, \theta) = \sum_{i=1}^n \log f(y_i, \theta) \quad (2.13)$$

$$\frac{\partial}{\partial \theta} L(\theta, y) = \sum_{i=1}^n \frac{\partial}{\partial \theta} \log f(y_i, \theta) = 0 \quad (2.14)$$

$$\psi = \frac{-f}{f} \quad (2.15)$$

$$\text{Var}(\theta) = [I(\theta)]^{-1} \quad (2.16)$$

$$I(\theta) = E \left(-\frac{\partial^2}{\partial \theta^2} L(\theta, y) \right) \quad (2.17)$$

$$\text{Var}(\hat{\theta}) \approx \left[-\frac{\partial^2}{\partial \theta^2} L(\theta, y) \Big|_{\theta=\hat{\theta}} \right]^{-1} \quad (2.18)$$

2.3 GoF-Tests

2.3.1 Kolmogorov-Smirnov Test

$$D = \sup_{y_i} \{F_n(y_i) - F(y_i, \theta)\} \quad (2.19)$$

2.3.2 Anderson-Darling Test

$$A^2 = -n - \sum_{i=1}^n \frac{2i-1}{n} \left[\log F(y_i, \hat{\theta}) + \log(1 - F(y_{n+1-i}, \hat{\theta})) \right] \quad (2.20)$$

2.3.3 Chi-Quadrat Test

2.4 Konfidenzintervalle

$$W_q = \frac{\lambda [\text{Var}(S) + (E(S))^2]}{2(1 - \lambda E(S))} \quad (2.21)$$

2.5 Konfidenzbänder

2.6 Coverage Error

2.7 Resampling Verfahren

2.7.1 Bootstrap

Kapitel 3

Vorstellung der Algorithmen

Banks, J. 1998. Handbook of simulation: - 7.2.3: Quantile Estimation

Was sind Voraussetzungen, die durch Bootstrap abgelöst werden?

Es werden im wesentlichen zwei Ansätze vorgestellt, die Resampling einsetzen, um Konfidenzbänder zu bestimmen.

Der erste Ansatz Setzt Bootstrap ein, um

3.1 Standard Bootstrap

3.2 Bootstrapping der Residuen

3.3 Parametrisches Bootstrap

3.4 Wild Bootstrap

3.5 Bayes'sches Bootstrap

3.6 Resampling von $\partial R(\alpha)$

Banks, J. 1998. Handbook of simulation: - 5: Random Variate Generation (S. 143 ff)

Kapitel 4

Implementierung

4.1 OMNeT++

4.1.1 Überblick

4.1.2 Simulationen

4.2 Parameterstudien in OMNeT++

4.2.1 Datenerfassung

4.2.2 Auswertung

4.2.3 Darstellung

4.3

Kapitel 5

Auswertung

5.1 Analytisches Verfahren

Eine Referenz [1].

5.2 parametrisches Bootstrapping

5.3 nicht-parametrisches Bootstrapping

5.4 Vergleich

Kapitel 6

Schlussenteil

6.1 Fazit

6.2 Ausblick

Anhang A

Weitere Informationen

Abbildungsverzeichnis

2.1	Arten von Systemstudien	5
2.2	M/M/1 Warteschlangenmodell	5
2.3	M/M/1 Zustandsübergangsdiagramm	6

Algorithmenverzeichnis

Literaturverzeichnis

- [1] AGGARWAL, ALOK und JEFFREY SCOTT VITTER: *The Input/Output Complexity of Sorting and Related Problems*. Communications of the ACM, 31(9):1116–1127, 1988.

Hiermit versichere ich, dass ich die vorliegende Arbeit selbstständig verfasst habe und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet sowie Zitate kenntlich gemacht habe.

Dortmund, den 28. Februar 2021

Muster Mustermann

